



Gaussian Mixture Model을 활용한 유압프레스 공정의 조기 이상 탐지

KAMP(Korea AI Manufacturing Platform)
제조AI 경진대회

곽준우, 천세환, 최정우

목차



서론

Fineblanking Press and Hydraulic Pump

❖ 유압펌프 이상은 왜 프레스 공정의 문제가 될까?

- 공정 조건: 소재 고정력·반대 방향 힘을 먼저 건 뒤 절단력 작용 → 세 힘이 안정적으로 유지되어야 정밀 절단면 확보
- 펌프 이상의 영향: 프레스 압력 불안정 → 가공품 불량·설비 비가동·검사 및 재작업 부담 증가
 - ✓ 주기적 점검 사이에 이상이 발생할 경우 손해 발생, 작업자 경험에 따라 판단 기준이 달라짐

유압펌프 이상

진동·전류 변화



압력 불안정


세 힘의 균형 붕괴



불량·비가동

검사·재작업·정지

Fineblanking: Three forces



F_R : 소재 고정력 / F_G : 반대 방향 힘 / F_S : 절단력


(그림: Feintool 공식 공정 자료)

서론

Problem Definition

❖ AI를 활용해 프레스 공정의 이상탐지를 어떻게 할 수 있을까?

- 조기 탐지: 프레스 유압펌프의 진동·전류 시계열 데이터로 초기 이상을 조기 탐지하는 예지 보전




사전지식

Multivariate Time-series Anomaly Detection

❖ 시계열 데이터 이상 탐지에는 어떤 방법이 있을까?

- 세 가지 접근: 예측(다음 값과의 오차) · 재구축(복원 오차) · 밀도(정상 분포에서의 희소도)
- 우리의 선택: 현재까지의 관측만으로 바로 점수를 내는 밀도 기반 GMM → 짧은 clip·정상 위주 데이터에 적합


예측 (Forecasting)



다음 값을 예측 → 실제와 차이가 크면 이상

AR(AutoRegressive), VAR(Vector AutoRegression), LSTM(Long Short-Term Memory)


재구축 (Reconstruction)



정상 패턴으로 복원 → 복원이 오차가 크다면 이상

PCA(Principal Component Analysis), AE(AutoEncoder)

밀도 (Density)



정상 분포 위의 확률 → 정상 분포와 멀어질수록 이상

GMM, KDE(Kernel Density Estimation), LOF(Local Outlier Factor)




사전지식

Hydraulic Pump Sensor Dataset

	TimeStamp	AI0_Vibration	AI1_Vibration	AI2_Current	Equipment_state
0	00:00.0	0.116967	-0.176403	192.33873	0
1	00:00.1	0.03008	-0.210895	217.00433	0
2	00:00.2	-0.045794	-0.029424	197.51062	0

❖ 우리의 데이터는 어떻게 생겼을까?

- 구성:
 - ✓ 정상 데이터셋 : 599 clip(19,999행)
 - ✓ 이상 데이터셋 : 21 clip(600행), 공백을 기준으로 clip 분리, clip 내부는 0.1초 간격
- Clip : 약 8초마다 최대 5초 동안 0.1초 간격으로 연속 수집되는 짧은 측정 구간



x축: clip 시작 후 경과 시간(초)

y축 :원시값 (상부/하부 매핑과 물리 단위는 미확인)


사전지식

Hydraulic Pump Sensor Dataset

	TimeStamp	AI0_Vibration	AI1_Vibration	AI2_Current	Equipment_state
0	00:00.0	0.116967	-0.176403	192.33873	0
1	00:00.1	0.03008	-0.210895	217.00433	0
2	00:00.2	-0.045794	-0.029424	197.51062	0

❖ 우리의 데이터는 어떻게 생겼을까?

- 구성:
 - ✓ 정상 데이터셋 : 599 clip(19,999행)
 - ✓ 이상 데이터셋 : 21 clip(600행), 공백을 기준으로 clip 분리, clip 내부는 0.1초 간격
- Clip : 약 8초마다 최대 5초 동안 0.1초 간격으로 연속 수집되는 짧은 측정 구간





사전지식

Semi-Supervised Deep Learning for Press Machine Anomaly Detection | Serradilla et al., 2021

❖ 기존의 프레스 공정에서는 어떻게 이상탐지를 하고 있을까?

- Semi-supervised: 고장 라벨이 드문 현장 → 정상만으로 정상성을 학습하고, 벗어난 정도(damage index)가 임계값을 넘으면 이상
- 프레스 사례 : stroke별 12개 센서를 2D-CNN-AE(2D Convolutional Neural Network AutoEncoder)로 복원 → 오차가 정상 검증 95 백분위를 넘으면 이상

Supervised vs. Semi-supervised



합성 고장 평균 F1


2D-CNN-AE	0.99
Null-space	0.92
현장 기술자	0.82

제안방법론


Why Density-based Detection?

❖ 우리의 데이터셋에는 어떤 이상 탐지 모델이 적합할까?

- 계승: 정상만 학습 + 정상 분위수 임계값이라는 semi-supervised 구조는 그대로 유지
- 차이: 짧은 clip에서 0.1초마다 판단해야 함 → **stroke 전체를 복원하는 AE 대신 짧은 창 의 희소도를 바로 재는 밀도 모델** 선택
 - ✓ 17개 방법 비교에서도 기본 GMM F1 0.928로 최고 → Experiments에서 검증



우리: 유압펌프 clip




공통 정상 데이터만 학습 · 정상 점수의 분위수로 임계값 결정 · 이상 라벨은 테스트셋에만 사용

제안방법론

Overall Framework

❖ 우리의 모델은 매 순간 어떻게 이상을 판단할까?

- 학습 (정상 데이터만): 정상 창 z 의 분포 $p(z)$ 를 GMM으로 학습하고, 보정 데이터로 경보 임계값 θ 결정
- 판단 (0.1초마다): 새 창의 점수 $s_t = -\log p(z_t)$ 가 θ 를 넘으면 그 시점에 경보



제안방법론

Causal Input Window

❖ 모델은 매 순간 무엇을 보고 판단할까?

- 입력 창: 과거 3시점 + 현재 1시점을 쌓은 $z_t = [x_{t-3}; x_{t-2}; x_{t-1}; x_t] (W = 3) \rightarrow 3\text{센서} \times 4\text{시점} = 12\text{차원}$
- 판단 규칙: clip 경계·미래 값은 사용하지 않고, 처음 3시점(0.0~0.2초)은 관측된 값만으로 판정

한 clip의 센서 기록 (0.1초 간격)

	0.0초	0.1초	0.2초	0.3초	0.4초	0.5초	0.6초
v0	v0	v0	v0	v0	v0	v0	
v1	v1	v1	v1	v1	v1	v1	
c	c	c	c	c	c	c	

미래

판단 3차원 6차원 9차원 $z_{0.3}$ $z_{0.4}$ $z_{0.5}$

0.0~0.2초는 창이 덜 차서 관측된 값만으로 판정 (3·6·9차원) → 0.3초부터 12차원 창

	$z_{0.3}$	$z_{0.4}$	$z_{0.5}$
t-3	v0	v0	v0
	v1	v1	v1
	c	c	c
t-2	v0	v0	v0
	v1	v1	v1
	c	c	c
t-1	v0	v0	v0
	v1	v1	v1
	c	c	c
t	v0	v0	v0
	v1	v1	v1
	c	c	c

0.1초씩 밀리며 매 시점 새 12차원 벡터 → 같은 색 = 같은 시점 값

판단 규칙

 미래 값 사용 X

현재 시점까지만 보고 판단 (실시간과 동일)

 경계 넘는 창 X

공백 사이 값을 이어 붙이거나 보간하지 않음


제안방법론

Gaussian Mixture Model

❖ GMM은 정상을 어떻게 표현할까?

- 혼합 분포: 정상 패턴 K개를 각각 종 모양 분포(산) 하나로 보고, 비중 π_k 만큼 섞어 $p(z)$ 표현
- EM(Expectation-Maximization) 학습: E-step(소속 확률 γ 계산) $\leftrightarrow$ M-step(γ 가중평균으로 산 갱신) 반복
✓ 아래는 1차원 · K = 2 예시 (실제 모델: 9차원 창, K = 4, full covariance)

① 초기값: 분포 2개 배치




정상 데이터 $z = 1, 2, 3, 5, 8, 9$

분포1 $\mu = 3, \sigma = 1.5, \pi = 0.5$

분포2 $\mu = 7, \sigma = 1.5, \pi = 0.5$

처음엔 임의의 두 분포로 시작

② E-step: 소속 확률 γ




막대 = 분포1(파랑) : 분포2(주황) 소속 비율

$z = 3 \rightarrow \gamma_1 = .133 / (.133 + .004) =$

~~0.97~~ $\rightarrow$ 두 분포 높이 같음 $\rightarrow 0.5 : 0.5$

분포 높이 = $\pi \cdot N(z | \mu, \sigma)$

③ M-step: 가중평균으로 갱신



$\mu_1 = \sum \gamma z / \sum \gamma = 8.45 / 3.47 = 2.43$


$\mu_2 = 19.55 / 2.53 = 7.73$

$\pi_1 = 3.47 / 6 = 0.58, \pi_2 = 0.42$

$\sigma_1^2 = 1.74, \sigma_2^2 = 2.46$ (γ 가중 분산)

$z = 5$ 는 두 분포에 절반씩 기여

④ 반복 $\rightarrow$ 정상과 이상 분리



$\mu = (2.75, 8.5), \pi = (.67, .33)$

$\rightarrow$ 정상 분포 $p(z)$ 완성

새 값의 점수 $-\log p(z)$

$z = 2 \rightarrow 1.9$ (흔함)

$z = 12 \rightarrow 21.1$ (드뭇 = 이상)


제안방법론

Anomaly Score and Alarm Threshold

❖ 언제 경보를 울릴까?

- 이상 점수: $s_t = -\log p(z_t) \rightarrow$ 학습한 정상 분포에서 드문 조합일수록 큰 값
- 경보 규칙: $\theta =$ 정상 보정 점수의 99 백분위, $s_t > \theta$ 인 시점만 경보 $\rightarrow$ 매 시점 재판단, 경보 유지 없음

이상 점수 (log)



실험

Evaluation Metric

❖ 성능은 무엇으로 평가할까?

- 시점 단위: 테스트 4,690시점(정상 4,090 + 이상 600) 전체의 F1 · FAR(False Alarm Rate) · Miss rate
- clip 단위 조기경보: 0.2·0.5초 이내 첫 경보 clip 비율, 정상 120 clip 중 경보 clip 비율
 - ✓ 기본 17종은 같은 대기 규칙 적용. 최종 GMM은 초기 주변분포 판정을 추가

	경보 O	경보 X
이상 600	TP 570.3	FN 29.7
정상 4,090	FP 11.7	TN 4,078.3

예: 최종 GMM, W = 3 (seed 평균, 시점 수)

F1

$$\frac{2TP}{2TP + FP + FN}$$

탐지와 오경보의 균형

FAR

$$\frac{FP}{FP + TN}$$

오경보의 비율

Miss rate

$$\frac{FN}{TP + FN}$$

이상을 놓친 비율

0.5초 이내 경보율

$$\frac{n(t_{delay} < 0.5)}{n(clip)}$$

0.5초 안에 첫 경보가 난 clip비율

TP (True Positive) · FP (False Positive) · TN (True Negative) · FN (False Negative)

$$t_{delay} = t_{alarm} - t_{onset}$$

실험

Benchmark of 17 Detectors


F1

$$\frac{2TP}{2TP + FP + FN}$$

❖ 여러 이상 탐지 방법 중 무엇이 가장 잘 잡아낼까?

- 밀도·거리 계열 우세: GMM F1 0.965, Mahalanobis 0.923 → 센서·시점 간 결합 분포를 보는 방법이 상위
- 복잡도 ≠ 성능: 신경망 계열 AE 0.696·MLP 0.640·LSTM 0.638·GRU 0.608으로 모두 0.7 미만
- ✓ W = 3 (과거 3시점 + 현재) 기준

F1 (W = 3, 테스트 4,690시점)



실험

Miss rate


Miss Rate

$$\frac{FN}{TP + FN}$$

❖ 실제 이상을 얼마나 놓칠까?

- GMM Miss rate 4.9%: 2위 Mahalanobis 12.7%의 절반 이하, 나머지 방법은 27.3~76.5%
- 차이는 clip 초반: 기존 방법은 창이 차기 전 0.0~0.2초 63시점 모두 미탐, GMM은 약 41시점 탐지

Miss rate (이상 테스트 600시점 중 미탐 비율)



실험

False Alarm Rate


FAR

$$\frac{FP}{FP + TN}$$

❖ 오경보를 얼마나 줄릴까?

- 모든 방법 FAR 0.4% 미만: 정상 보정 99 백분위 임계값을 공통 적용 → GMM 0.29%로 다른 방법과 같은 수준
- 낮은 FAR ≠ 좋은 탐지: Persistence 0.00%·IsolationForest 0.03%는 경보 자체가 적어 Miss rate 65% 이상

FAR (정상 테스트 4,090시점 중 오경보 비율)



실험

Early Detection Performance


0.5초 이내 경보율

$$\frac{n(t_{delay} < 0.5)}{n(clip)}$$

❖ 얼마나 가장 빨리 잡아낼까?

- 첫 경보 속도: GMM은 이상 21 clip 모두 0.5초 내 경보, 그중 20개는 0.3초 이내 (11개는 첫 관측 0.0초)
- 판단 시작 차이: 기존 방법은 창이 차는 0.3초부터 판단 → Mahalanobis 95.2%, 신경망 60~71%

0.5초 이내 첫 경보율 (이상 21 clip 기준)



실험


Effect of Window Length

❖ 과거(W)를 얼마나 길게 봐야 할까?

- $W \geq 3$ 에서 F1 포화: 0.954~0.966, 첫 경보는 W와 무관하게 평균 약 0.11초
- $W = 3$ 채택: $W \geq 5$ 부터 오경보 시점 18~33개로 증가 ($W = 3$: 11.7개)
- ✓ 초기 주변분포 판정으로 창이 다 차기 전에도 판단 → 긴 W의 판단 대기 비용이 사라짐


F1

(전체 테스트 시점, seed 평균)



평균 첫 경보 시각

(이상 clip 시작 후)



창이 다 차는 시각

0.5초 이내 경보 clip

오경보 시점 수 (FP)


0.1초	0.2초	0.3초	0.5초	0.8초	1.0초	1.5초	2.0초	3.0초
15/21	21/21	21/21	21/21	21/21	21/21	21/21	21/21	21/21
8.0	10.0	11.7	20.0	19.7	23.0	33.0	18.7	18.3

실험

Sensor Ablation

❖ 높은 성능은 어느 센서에서 나올까?

- 센서 제거 F1: 3센서 0.965 → 전류만 0.955 → 진동만 0.839, 성능 대부분이 전류에서 나옴
- 진동만 모델: 2 clip(fault_0020-0021)은 끝까지 무경보, 0.5초 이내 첫 경보 76.2%
 - ✓ 최종 GMM, $W = 3$ (입력 차원 = 4시점 × 센서 수) · 센서만 바꿔 처음부터 재학습, seed 0-1-2 평균



입력	입력 차원	F1	FAR	Miss
3센서	12	0.965	0.29%	4.9%
전류만	4	0.955	0.15%	7.6%
진동만	8	0.839	0.44%	25.6%

현장 활용성

Field Deployment and Next Steps

❖ 현장에 적용하면 어떻게 쓸 수 있을까?

- 운용 흐름: 0.1초 온라인 판단 → 경보 시 파형·점수·운전 조건 저장 → 작업자의 점검·정지 판단 지원
- 확장 검증: 운전조건별 정상 분포·임계값, 동일 수집 조건의 독립 고장 기록으로 전류 기여 재평가
 - ✓ 추론·통신·제어 지연과 불량·비가동 감소 효과는 아직 측정하지 않음

입력: 센서 원시 데이터 (한 줄 = 0.1초)


정상 운전 · 2022-07-12

TimeStamp	진동0	진동1	전류
01:00:50.060	0.075	-0.043	93.2
01:00:50.160	-0.036	-0.001	110.6
01:00:50.260	-0.048	-0.024	115.7
01:00:50.360	0.064	0.079	107.3

이상 기록 · 2022-07-17

TimeStamp	진동0	진동1	전류
10:51:16.724	0.316	0.205	34.6
10:51:16.824	-0.303	0.309	70.3
10:51:16.924	-0.209	0.247	151.4
10:51:17.024	-0.103	0.253	147.8

출력: 판정 결과



입력 차원(θ)	이상 점수	판정
3 (8.4)	3.5	정상
6 (12.7)	5.0	정상
9 (15.4)	4.7	정상
12 (17.2)	6.0	정상


입력 차원(θ)	이상 점수	판정
3 (8.4)	14.2	이상 → 경보
6 (12.7)	42.6	이상 → 경보
9 (15.4)	73.8	이상 → 경보
12 (17.2)	91.6	이상 → 경보

현장 활용성

Field Deployment and Next Steps

❖ 현장에 적용하면 어떻게 쓸 수 있을까?

- 운용 흐름: 0.1초 온라인 판단 → 경보 시 파형·점수·운전 조건 저장 → 작업자의 점검·정지 판단 지원
- 확장 검증: 운전조건별 정상 분포·임계값, 동일 수집 조건의 독립 고장 기록으로 전류 기여 재평가
 - ✓ 추론·통신·제어 지연과 불량·비가동 감소 효과는 아직 측정하지 않음




감사합니다

부록

Error Analysis: Missed Detections

❖ 미탐은 언제, 왜 발생할까?

- W=3 기본 미탐 71개 중 63개는 초기 미판정 → 최종 41개 추가 탐지 (63 → 22, seed 0)
- 남은 미탐은 대부분 첫 경보 이후 발생: 진동이 작고 전류 변화가 완만해 정상 학습 패턴과 가까운 시점
✓ 시점 미탐은 남아도 끝까지 놓친 이상 clip은 0 / 21 (seed 0·1·2 모두)



놓친 시점 vs 잡은 시점: 최근 4관측 센서 특성 (중앙값, seed 0)

항목	놓친 (8)	잡은 (529)	의미
상부·하부 진동 최대 흔들림	0.060·0.085	0.188·0.199	놓친 순간은 진동이 약 1/3로 작음
전류가 0.1초 사이 바뀐 양	18.5	54.8	미탐 시점의 전류 변화가 더 완만
전류 절댓값 최댓값	178.2	151.4	미탐에서 오히려 큼 → 크기만으로 구분 어려움
가장 비슷한 정상과의 거리	1.24	2.88	놓친 순간은 정상과 아주 가까움

정리: 놓친 순간은 '잠깐 정상처럼 보인' 순간


미탐은 정상 학습 분포에 더 가까움. 시점별 고장 징후 정답이 없어 물리적 원인 확인은 어려움

부록



Error Analysis: False Alarms

❖ 오경보는 어떤 정상 운전에서 발생할까?

- seed 0: 정상 570번째 clip 10시점, 564번째 clip 1시점. seed 1-2: 570번째 clip만 경보
- seed 0 오경보 시점: 상부 진동 약 3.1배·전류 약 1.5배. 드문 정상 운전 조합에서 발생
 - ✓ 조건부 희귀도: 570번째 clip은 상부 진동, 564번째 clip은 진동 두 채널의 조합이 두드러짐



● 경보 ● 경보 없음



2 / 120 오경보가 발생한 정상 clip 수

570번째 clip 공통 564번째 clip의 1시점 경보는 seed 0에서만 발생

부록

Error Analysis: Summary

❖ 모델은 언제 잘 작동하고, 언제 실패할까?

- 데이터에 압력·속도 등 공정 변수가 없어 공정조건을 센서 상태 조건으로 정의
 - ✓ 수치는 최종 GMM(초기 주변분포) 기준, seed 0.1.2 평균

잘 작동하는 조건

100%

진동·전류가 함께 정상 범위를 벗어난 이상
이상 clip 21개 모두 0.5초 내 경보, 0.2초 내 85.7%

52%

clip 시작 직후 (0.0초 첫 관측)
관측된 센서만으로 판정, 11 / 21 clip 첫 관측에서 경보

2개

진동은 작고 전류만 변한 이상
진동만 모델이 놓친 20.21번째 clip을 3센서 모델은 탐지

실패하는 조건

4.9%

이상 중 진동이 일시적으로 정상 수준인 구간
시점 미탐 발생 (첫 경보 이후 대부분)

**평균 1.3
clip**

정상이지만 전류·진동이 평소보다 큰 운전
정상 120 clip 중 평균 1.3 clip 경보

**평균
21.7**

clip 처음 3시점의 남은 미탐
관측 1~3개만으로는 정상과 구분이 어려운 시점


부록

Robustness to Current Recording Format

❖ 전류 기록 형식이 특이한데, 결과가 그 형식 때문일까?

- 이상 구간 전류값은 1.1920929 간격으로 기록(정상은 1.9%만) → 형식을 통일·제거한 조건에서 재학습해 비교
- 형식 통제 후 최종 F1 0.965 유지. 레벨 제거 후 0.942, 기본 모델끼리는 Mahalanobis가 소폭 우세
✓ 격자 간격은 정상 전류 표준편차의 0.94% → 연속 밀도 모델은 이산적인 기록 형식에 민감하지 않음

조건별 F1 (3 센서, W=3)



실험 조건과 최종 GMM F1

조건	F1
원본	0.965
정상 전류를 같은 간격으로 반올림	0.965
이상 전류 격자 제거 ($\pm$ 간격/2 잡음)	0.965
전류 레벨 제거 (창 내 1차 차분만)	0.942
참고: 진동만 입력	0.839

GMM·IsolationForest는 seed 0·1·2 평균, 나머지는 결정론적 1회


부록

Variable Interaction

❖ 센서 간 관계를 함께 보면 더 잘 잡을까?

- 센서별 독립 모델 → 센서 간 관계 추가 → 센서·시점 공분산 → 혼합 공분산 순으로 F1이 단계적으로 상승
- W=3 진동만 모델이 놓친 20·21번째 clip을 3센서 모델은 모두 0.5초 내 경보
 - ✓ 단일 변수의 크기보다 변수 간 결합 패턴이 이상 판별에 중요

변수 관계 반영 수준에 따른 F1 (W=3)



진동만으로는 놓친 이상 clip의 시점 탐지율

이상 clip	진동만	3센서 (최종)
이상 데이터 4번째 (진동만도 탐지)	10.8%	87.1%
이상 데이터 20 번째	0.0%	80.0%
이상 데이터 21 번째	0.0%	66.7%

전류만 **0.955** · 진동만 **0.839** · 3센서 **0.965**
두 센서를 함께 쓸 때 미탐률이 가장 낮음 (4.9%)

부록

Effect of Window Length: All Methods

❖ W(과거 시점 수)를 바꾸면 방법별 성능은 어떻게 달라질까?

- 기존 방법은 W가 길수록 대기 구간이 미탐으로 쌓여 하락, 최종 GMM은 $W \geq 3$ 에서도 F1 0.95~0.97 유지
 - ✓ 모든 테스트 시점 기준 F1, seed 반복 방법(GMM·MLP·LSTM·GRU·AE)은 seed 0·1·2 평균

방법	W=1	W=2	W=3	W=5	W=8	W=10	W=15	W=20	W=30
GMM (최종)	0.681	0.939	0.965	0.964	0.965	0.963	0.954	0.966	0.965
GMM (기본)	0.665	0.917	0.928	0.893	0.839	0.799	0.696	0.606	0.391
Mahalanobis	0.635	0.895	0.923	0.895	0.840	0.801	0.702	0.602	0.391
VAR_Ridge	0.568	0.622	0.611	0.695	0.809	0.782	0.700	0.606	0.385
MLP	0.550	0.642	0.640	0.735	0.810	0.787	0.692	0.600	0.377
LSTM	0.563	0.670	0.638	0.738	0.797	0.783	0.685	0.592	0.356
GRU	0.561	0.662	0.608	0.729	0.782	0.780	0.683	0.597	0.379
PCA	0.496	0.683	0.779	0.764	0.774	0.780	0.696	0.600	0.388
AutoEncoder	0.618	0.609	0.696	0.754	0.734	0.783	0.695	0.601	0.386
LOF	0.681	0.742	0.830	0.859	0.820	0.786	0.692	0.593	0.384

최종 GMM은 clip 처음 W개 시점을 관측된 값의 주변분포로 판정, 나머지 방법은 W개 시점을 기다린 뒤 판정 (W=30의 최대 가능 F1 0.391)

부록

Effect of Window Length: Final GMM Detail

❖ 최종 GMM에서 W를 바꾸면 무엇이 달라질까?

- $W \geq 3$ 에서 F1 0.954~0.966, 첫 경보 약 0.11초로 W와 거의 무관 → 기다리는 비용이 사라짐
- 기존 W 비교를 참고해 최종 W=3 채택. 독립 검증은 향후 수행
✓ seed 0.1.2 평균

W	F1	오경보 FP (시점)	경보한 정상 클립	0.5초 내 경보 클립	평균 첫 경보
1	0.681	8.0	2.7 / 120	71.4%	0.29초
2	0.939	10.0	2.0 / 120	100%	0.11초
3(채택)	0.965	11.7	1.3 / 120	100%	0.11초
5	0.964	20.0	1.3 / 120	100%	0.11초
8	0.965	19.7	1.0 / 120	100%	0.11초
10	0.963	23.0	1.0 / 120	100%	0.10초
15	0.954	33.0	1.0 / 120	100%	0.11초
20	0.966	18.7	1.0 / 120	100%	0.11초
30	0.965	18.3	1.0 / 120	100%	0.11초

참고 문헌

Anomaly Detection, Evaluation, and GMM

- Pang, G. et al. (2021). Deep Learning for Anomaly Detection: A Review. ACM Computing Surveys. DOI 10.1145/3439950
- Hundman, K. et al. (2018). Detecting Spacecraft Anomalies Using LSTMs and Nonparametric Dynamic Thresholding. KDD
- Malhotra, P. et al. (2016). LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection. ICML Workshop
- Kim, S. et al. (2022). Towards a Rigorous Evaluation of Time-series Anomaly Detection. AAAI
- Stanford CS229. Mixtures of Gaussians and the EM Algorithm (lecture notes)
- scikit-learn documentation. Gaussian mixture models: EM, covariance types, BIC
- Feintool. Successful Fineblanking (process forces and sensor-based monitoring)
- Serradilla et al., (2021). Adaptable and Explainable Predictive Maintenance: Semi-Supervised Deep Learning for Anomaly Detection and Diagnosis in Press Machine Data. Applied Science